LAPORAN PROJECT
PENGOLAHAN CITRA DIGITAL
S1 SAINS DATA - UNIVERSITAS NEGERI SURABAYA

IDENTITAS PROYEK	
Judul	Analisis Perbandingan Performa Klasifikasi Citra X-Ray COVID-19 Menggunakan Metode Machine Learning GLCM-SVM dan Deep Learning MobileNet dengan Preprocessing CLAHE
Topik	COVID-19 *Classification*
Identitas Penyusun	1. Eka Aliya (24031554012) 2. Salsabila Alika Seftizianka (24031554117) 3. Atya Azharina Aziz (24031554194)
Kelas	2024A

1. PENDAHULUAN

1.1 Latar Belakang

Pandemi COVID-19 merupakan wabah penyakit menular global yang menyebar pada akhir tahun 2019 disebabkan oleh varians virus corona baru, *Severe Acute Respiratory Syndrome Coronavirus 2* (*SARS-CoV-2*). Menurut *World Health Organization* (*WHO*), awal mula wabah ini, terdeteksi di Wuhan, Tiongkok, dengan gejala klinis umumnya meliputi demam, batuk, pilek, sakit tenggorokan, dan gangguan pernapasan. Untuk mendiagnosis seseorang terkena COVID-19 secara cepat dan akurat, diperlukan metode pemeriksaan seperti penggunaan *Chest X-Ray.*

X-ray menjadi alternatif penting dalam mengevaluasi kondisi paru-paru pasien secara visual, hal ini dikarenakan ketersediaannya yang luas dan biaya operasionalnya yang lebih rendah dibandingkan pemindaian *CT-Scan.* Namun, interpretasi manual oleh radiologi seringkali terkendala oleh adanya kemiripan visual antara COVID-19 dengan Viral Pneumonia. Selain itu, kualitas citra *X-Ray* yang memiliki kontras rendah seringkali menyamarkan adanya perubahan struktural yang abnormal pada organ paru-paru, sehingga diperlukan adanya solusi berbasis pengolahan citra digital untuk membantu proses klasifikasi secara otomatis dan akurat. Untuk mengatasi kendala dalam kualitas citra, metode *Contrast Limited Adaptive Histogram Equalization* (*CLAHE*) digunakan sebagai salah satu tahap *preprocessing*. *CLAHE* berperan dalam menonjolkan perubahan fitur tekstur pada paru-paru tanpa merusak citra aslinya secara berlebihan, sehingga mempermudah identifikasi pola infeksi secara digital. Hal ini didukung oleh studi literatur yang menunjukkan bahwa CLAHE mampu memberikan hasil citra yang lebih jelas dibandingkan *Histogram Equalization* (HE) standar, dibuktikan dengan perolehan nilai PSNR yang lebih tinggi dan MSE yang lebih rendah.

Penerapan pengolahan citra ini dapat dilakukan melalui dua pendekatan yaitu metode klasik dan modern. Metode klasik berbasis *Support Vector Machine (SVM)* mengedepankan adanya ekstraksi fitur tekstur secara manual seperti *Gray Level*

Co-occurrence Matrix (GLCM) guna mengenali karakteristik khusus pada citra. Disisi lain, metode modern berbasis *deep learning* melalui arsitektur *MobileNet* memungkinkan sistem untuk mempelajari fitur secara otomatis dengan struktur yang lebih mendalam namun tetap efisien. Penelitian ini bertujuan untuk membandingkan kedua pendekatan tersebut guna menentukan metode yang paling optimal dalam klasifikasi kondisi COVID-19, Viral Pneumonia, dan Normal melalui citra *X-ray.*

Rumusan Masalah:

1. Bagaimana penerapan *preprocessing* pada citra *X-ray* COVID-19?
2. Bagaimana implementasi metode *GLCM-SVM* dan *MobileNet* dalam klasifikasi *X-ray*?
3. Bagaimana perbandingan performa metode GLCM-SVM dan MobileNet berdasarkan accuracy, precision, recall, F1-score, dan confusion matrix?

1.2 Pendekatan pemecahan masalah

Strategi pemecahan masalah dalam penelitian ini difokuskan pada peningkatan kualitas informasi citra medis dan perbandingan dua model klasifikasi yang berbeda. Tahap awal dilakukan melalui *preprocessing* dengan metode utama *Contrast Limited Adaptive Histogram Equalization* (*CLAHE*) untuk mengatasi kendala kontras rendah pada citra *X-ray*, yang secara literatur terbukti lebih unggul dibanding *Histogram Equalization (HE)* dalam menonjolkan fitur patologis seperti pola opasitas jaringan (*ground-glass opacity*). Melalui rangkaian tahapan preprocessing seperti konversi *grayscale*, metode CLAHE, penyeragaman ukuran dimensi citra (*resizing*), serta normalisasi nilai piksel, data dipersiapkan agar optimal bagi proses ekstraksi ciri maupun pelatihan model jaringan saraf tiruan.

Selanjutnya, penelitian ini menerapkan analisis komparatif performa antara metode klasifikasi berbasis ekstraksi fitur klasik dan metode *deep learning*. Pendekatan pertama menggunakan metode kombinasi *GLCM-SVM* untuk mengekstraksi informasi tekstur melalui perhitungan statistik derajat keabuan piksel yang meliputi nilai *contrast, correlation, energy, homogeneity, dissimilarity,* dan *Angular Second Moment (ASM).* Sementara itu, pendekatan kedua menggunakan metode *deep learning* dengan arsitektur *MobileNet* yang mampu mempelajari representasi fitur citra secara otomatis dan efisien melalui teknik *depthwise separable convolutions*. Evaluasi akhir dilakukan secara komprehensif menggunakan *Confusion Matrix* dengan metrik akurasi, presisi, *recall*, dan *F1-score* guna menentukan efektivitas metode *Machine Learning GLCM-SVM* dan *Deep Learning MobileNet* dalam mendiagnosis kondisi COVID-19, *Viral Pneumonia*, dan Normal secara akurat.

2. Metodologi

2.1 Eksplorasi Dataset

Dataset yang digunakan dalam penelitian ini diperoleh dari “COVID-19 Image Dataset” melalui platform *Kaggle,* dengan total keseluruhan 317 citra medis. Berdasarkan hasil eksplorasi yang kami lakukan, data tersebut terbagi ke dalam

struktur folder *train* (251 citra) dan folder *test* (66 citra). Dengan rincian datanya pada masing-masing objek yaitu:

1. COVID-19 memiliki 111 data *train* dan 26 data *test*
2. Viral Pneumonia memiliki 70 data *train* dan 20 data *test*
3. Normal memiliki 70 data *train* dan 20 data *test*

Lalu jika dilihat secara karakteristik visualnya, terdapat perbedaan pada pola spasial derajat keabuan dari ketiga objek. Pada citra Normal, bagian rongga paru-paru didominasi oleh area gelap transparan. Pada citra COVID-19 terdapat pola opasitas jaringan berupa bayangan putih pada area sekitar Perifer paru-paru. Pada citra Viral Pneumonia, terdapat bayangan putih yang sama, namun penyebaran nya terjadi di area tengah serta cenderung lebih masif.

2.2 Langkah Penelitian

Tahapan Penelitian yang dilakukan adalah sebagai berikut:

1. Pengumpulan dataset citra *X-ray COVID-19* dari Kaggle.
   Proses penelitian diawali dengan pengumpulan dataset citra medis berupa X-ray paru-paru yang diperoleh dari Kaggle, khususnya pada dataset "*COVID-19 Radiography Database*". Data tersebut mencakup tiga kategori diagnosis utama, yaitu citra paru-paru pasien terkonfirmasi COVID-19, pasien dengan Viral Pneumonia, serta citra paru-paru Normal. Pemilihan dataset ini bertujuan agar model yang dikembangkan memiliki referensi visual yang cukup untuk membedakan karakteristik patologis antara infeksi virus spesifik dan kondisi kesehatan paru-paru yang normal.
2. Melakukan *preprocessing* dengan mengubah Citra menjadi Grayscale dan penerapan metode CLAHE.
   Selanjutnya dilakukan tahap *preprocessing* yang bertujuan untuk menyeragamkan format citra dan menonjolkan fitur-fitur penting.Tahap preprocessing dilakukan dengan dua jalur berbeda (jalur GLCM-SVM dan jalur MobileNet). Pertama pada jalur GLCM-SVM, citra dikonversi menjadi format *Grayscale* karena informasi warna (RGB) tidak memiliki signifikansi medis pada analisis X-ray dan justru dapat menambah beban komputasi. Selanjutnya, diterapkan metode *Contrast Limited Adaptive Histogram Equalization* (CLAHE) untuk meningkatkan kontras gambar secara adaptif. CLAHE berfungsi memperjelas detail area yang terlalu gelap atau terang serta mempertajam batas tekstur seperti pola opasitas jaringan (*ground-glass opacity*) yang menjadi indikator khas infeksi paru-paru, tanpa menimbulkan *noise* berlebihan.
3. Melakukan *resize* dan normalisasi citra agar ukurannya sama.
   Setelah kualitas citra ditingkatkan, dilakukan tahap *resize* untuk menyamakan dimensi seluruh data citra menjadi ukuran standar (misalnya 224x224 piksel). Penyeragaman ini dilakukan agar data citra dapat diproses oleh MobileNet yang memiliki input tetap, serta menjamin konsistensi panjang vektor fitur pada metode klasik. Khusus pada jalur *MobileNet,* citra dipertahankan dalam format 3-channel (RGB) dan dilakukan Normalisasi otomatis menggunakan fungsi preprocess_input untuk mengubah rentang nilai piksel dari 0-255 menjadi skala -1.0 hingga 1.0. Sementara itu, pada jalur GLCM-SVM, hasil ekstraksi fitur nantinya akan dinormalisasi ke skala 0–1 menggunakan

MinMaxScaler. Langkah normalisasi pada kedua jalur ini sangat krusial untuk mempercepat proses konvergensi saat pelatihan model dan mencegah nilai intensitas atau fitur yang tinggi mendominasi perhitungan bobot dalam algoritma klasifikasi.

4. Pendekatan pertama menggunakan metode *GLCM* untuk ekstraksi fitur dan *SVM* untuk klasifikasi citra.

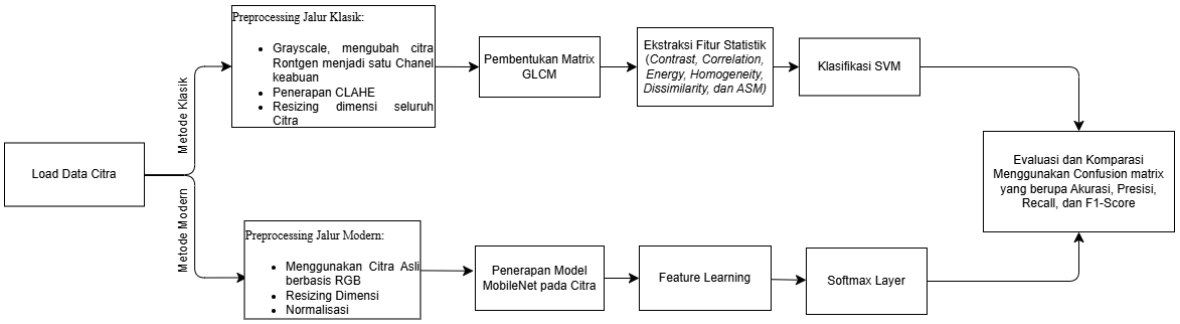
   Pada pendekatan pertama, penelitian menggunakan teknik analisis tekstur berbasis statistik melalui metode *Gray Level Co-occurrence Matrix* (*GLCM*). Dari matriks ini, diekstraksi beberapa parameter fitur statistik seperti *Contrast, Correlation, Energy, Homogeneity, Dissimilarity,* dan *ASM* yang merepresentasikan karakteristik permukaan paru-paru. Sebelum memasuki tahap pemodelan, seluruh fitur hasil ekstraksi tersebut dinormalisasi menggunakan metode *MinMaxScaler* guna menyelaraskan rentang nilai fitur ke dalam skala 0 hingga 1. Hasil ekstraksi fitur yang telah ditransformasikan ini kemudian digunakan sebagai input untuk algoritma *Support Vector Machine* (*SVM*) dengan kernel *Radial Basis Function* (*RBF*). *SVM* bekerja dengan mencari *hyperplane* atau batas pemisah optimal dalam ruang multidimensi guna mengklasifikasikan data ke dalam tiga kategori target berdasarkan kesamaan pola fiturnya.
5. Pendekatan kedua menggunakan *MobileNet* sebagai metode *deep learning* untuk klasifikasi citra.

   Pendekatan kedua menggunakan metode *Deep Learning* dengan mengimplementasikan arsitektur *MobileNet*. Berbeda dengan pendekatan pertama, MobileNet mampu melakukan ekstraksi fitur secara otomatis melalui lapisan konvolusi (*Feature Learning*) tanpa memerlukan intervensi manual peneliti. Metode yang digunakan adalah *Transfer Learning*, di mana model yang telah dilatih dengan citra training disesuaikan kembali untuk mengenali objek spesifik citra medis. *MobileNet* dipilih karena desainnya yang ringan dan efisien, namun tetap memiliki performa tinggi dalam menangkap representasi spasial yang kompleks pada citra X-ray.
6. Melakukan evaluasi performa model menggunakan *accuracy, precision, recall, F1-score* dan *confusion matrix*

   Untuk mengukur keandalan dari kedua pendekatan tersebut, dilakukan evaluasi performa menggunakan berbagai metrik pengujian. Metrik yang digunakan meliputi *Accuracy* untuk melihat ketepatan model secara umum, *Precision* untuk mengukur keakuratan prediksi positif, *Recall* untuk melihat kemampuan model dalam menemukan seluruh data positif, hal ini penting untuk menghindari diagnosa pasien sakit yang terlewat, serta *F1-Score* sebagai keseimbangan antara keduanya. Selain itu, digunakan *Confusion Matrix* sebagai alat bantu visual untuk menganalisis distribusi kesalahan klasifikasi antar kelas, sehingga dapat diketahui kelas mana yang paling sering mengalami salah deteksi.
7. Membandingkan hasil klasifikasi antara metode *GLCM-SVM* dan *Mobile Net*

   Tahap akhir dari penelitian ini adalah melakukan perbandingan antara hasil klasifikasi metode klasik (*GLCM-SVM*) dengan metode modern (*MobileNet*). Analisis dilakukan dengan membandingkan nilai-nilai metrik evaluasi yang telah diperoleh untuk menjawab rumusan masalah mengenai efektivitas kedua

metode tersebut dalam mendeteksi COVID-19. Perbandingan ini bertujuan untuk membuktikan apakah pendekatan ekstraksi fitur manual masih relevan atau apakah pendekatan *Deep Learning* memberikan peningkatan performa yang signifikan dalam otomatisasi diagnosa medis berbasis citra X-ray.



Gambar 1. Diagram Alur Pengerjaan Proyek

3. Hasil Analisis

A. *Preprocessing* pada Citra X-ray COVID-19

Tahapan *preprocessing* pada penelitian ini dirancang untuk mengkondisikan citra *Chest X-Ray* mentah yang memiliki kontras rendah menjadi lebih optimal dan siap untuk proses ekstraksi fitur. Arsitektur model klasik dan model deep learning modern memiliki kebutuhan input dengan karakteristik yang berbeda, maka dari itu *Preprocessing* dilakukan dengan membagi menjadi dua jalur setelah dilakukan penyeragaman resolusi dimensi. Tahapan *Preprocessing* yang dilakukan sebagai berikut:

- *Image Resizing*

  Citra rontgen yang diperoleh dari sumber dataset memiliki resolusi awal yang bervariasi. Oleh karena itu, dilakukan tahap awal berupa pengubahan dimensi panjang dan lebar dari seluruh citra menjadi ukuran standar yaitu 224 x 224 piksel. Penyeragaman dimensi merupakan prasyarat dari dimensi input tetap pada arsitektur MobileNet, sekaligus menjamin konsistensi ukuran panjang vektor matriks pada ekstraktor fitur klasik.

- Jalur 1: Pemrosesan Khusus Fitur Klasik *(GLCM, LBP, HOG, GLRLM)*

  Setelah dilakukan penyeragaman ukuran dimensi, citra dialirkan ke jalur pertama yang dikondisikan khusus untuk algoritma ekstraksi tekstur konvensional melalui tahapan:

  1. Konversi Grayscale

     Grayscale adalah tahapan mengubah citra rontgen yang memiliki format *multi-channel* (*RGB*) menjadi satu channel keabuan. Langkah ini diperlukan untuk mereduksi matriks piksel yang tidak diperlukan sekaligus memenuhi syarat fungsional algoritma klasik *GLCM* yang hanya bekerja pada derajat keabuan tunggal.

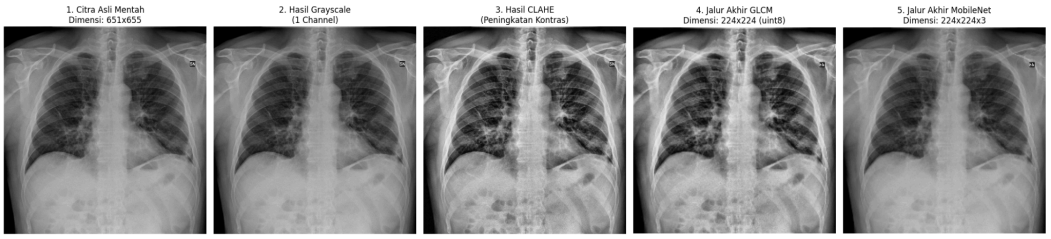
  2. Contrast Limited Adaptive Histogram Equalization (CLAHE)

     Metode ini diterapkan untuk meningkatkan kontras lokal dan kualitas visual citra rontgen secara adaptif. CLAHE bekerja

dengan membagi citra menjadi wilayah-wilayah kecil (*tiles*) dan membatasi penyebaran nilai kontrasnya. Hal ini sangat krusial pada citra medis untuk menonjolkan opasitas atau corak tekstur halus pada jaringan paru-paru tanpa memperbesar gangguan *noise* di area latar belakang. Pada jalur klasik ini, nilai intensitas piksel dipertahankan dalam format asli bilangan bulat (*integer*) berrentang 0–255.

- Jalur 2: Pemrosesan Khusus Deep Learning (MobileNet)
  Untuk kebutuhan pemodelan modern, citra rontgen hasil *resizing* tetap dipertahankan dalam format warna asli (RGB 3-channel) guna menjaga kekayaan informasi gradasi warna, namun diberikan transformasi nilai intensitas melalui tahapan:
  1. Normalisasi Nilai Piksel
     Normalisasi nilai piksel adalah mentransformasi skala intensitas kecerahan warna piksel citra yang awalnya bernilai rentang 0–255 menjadi skala linear -1 hingga 1 menggunakan fungsi *preprocess_input.* Standarisasi rentang nilai ini bertujuan untuk menyelaraskan distribusi data input dengan karakteristik bobot awal (*pre-trained weights* ImageNet) yang tertanam pada MobileNet, sehingga dapat mempercepat waktu konvergensi dan menjaga stabilitas performa model saat pelatihan berlangsung.

Berikut adalah hasil citra yang sebelum dan sudah dilakukan *preprocessing*



Gambar 2. Perbandingan Citra Asli dengan Hasil *Preprocessing*

Berdasarkan gambar tersebut perubahan karakteristik citra X-Ray pasien COVID-19 dapat diamati secara langsung pada setiap tahapannya.

- Gambar 1 merupakan citra asli yang dimuat dari dataset dengan dimensi awal 651 x 655 piksel. Pada kondisi ini, citra cenderung redup, berkabut, memiliki kontras global yang rendah, serta masih menyimpan informasi warna *multi-channel* (*RGB*) tersembunyi yang tidak efisien untuk komputasi citra klasik.
- Gambar 2 merupakan citra yang sudah dilakukan *Grayscale*. Citra sudah berhasil direduksi menjadi satu *channel* keabuan dengan derajat intensitas 0-255. Secara visual citra hasil *grayscale* tidak jauh berbeda dengan citra asli karena citra sli yang berupa X-Ray, namun secara dimensi jauh lebih ringan karena informasi warna yang tidak diperlukan telah dieliminasi.
- Gambar 3 merupakan citra hasil proses *CLAHE*. Pada tahap ini terjadi perubahan visual yang paling signifikan. Melalui perataan histogram lokal yang adaptif, area paru-paru yang tadinya redup dan gelap kini dipertegas kontrasnya. Pola patologis berupa flek putih atau bayangan

kabur akibat infeksi COVID-19 di paru-paru kanan dan kiri bawah terlihat menjadi sangat tajam, kontras, dan memiliki detail tekstur yang jelas.

- Gambar 4 merupakan tahap akhir dari jalur GLCM. Gambar 4 Menampilkan luaran akhir dari Gambar 3 yang telah diubah ukurannya menjadi dimensi standar 224 x 224 piksel dengan tipe data uint8 dengan rentang nilai tetap 0–255. Meskipun resolusi spasialnya mengecil, detail corak tekstur putih hasil penajaman CLAHE tetap terjaga dengan sangat baik. Format matriks bilangan bulat pada Gambar 4 inilah yang siap diekstrak fiturnya secara optimal menggunakan metode GLCM, LBP, HOG, dan GLRLM.
- Gambar 5 Menampilkan kondisi citra yang dialirkan khusus untuk menuju mesin deep learning. Berbeda dengan Gambar 4, Jalur MobileNet mempertahankan format warna asli RGB 3-channel (224 x 224 x 3) tanpa intervensi filter CLAHE untuk menjaga keaslian gradasi pendaran rontgen mentah. Nilai intensitas piksel pada visualisasi Gambar 5 ini secara sistematis telah ditransformasikan ke skala -1 hingga 1 guna memenuhi syarat standarisasi bobot awal (pre-trained weights ImageNet) sebelum memasuki arsitektur MobileNet.

B. Implementasi Metode *GLCM-SVM* dan *MobileNet* dalam Klasifikasi Citra X-ray

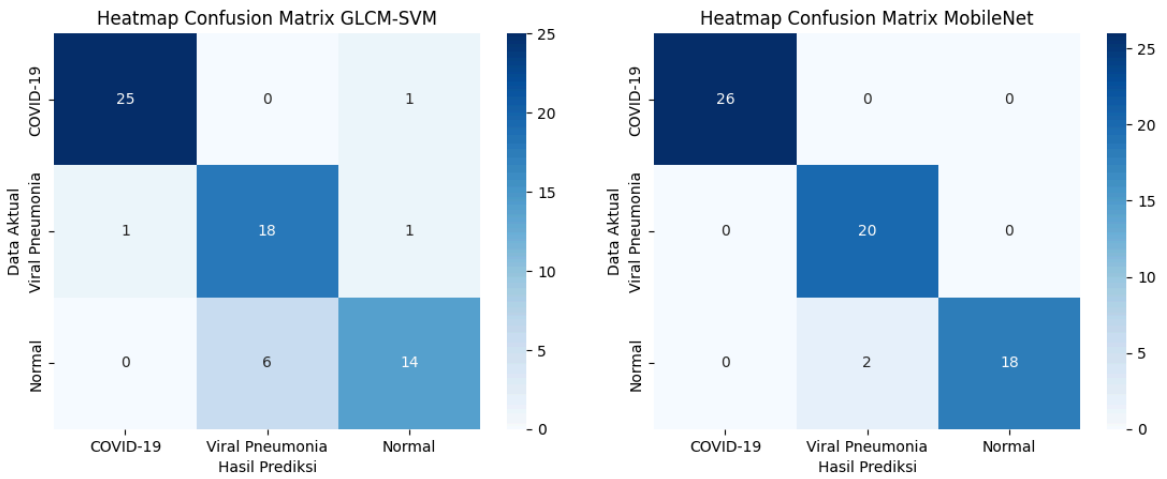
Implementasi pendekatan dengan metode klasik yaitu GLCM-SVM dalam mengklasifikasikan citra X-ray diawali dengan melakukan ekstraksi ciri tekstur dengan metode Gray Level Co-occurrence Matrix (GLCM). Co-occurrence Matrix dihitung dengan jarak (d)=2 dan empat variasi sudut yaitu 0°, 45°, 90°, dan 135° guna menangkap adanya pola hubungan antar-piksel secara komprehensif. Melalui matriks yang terbentuk, dilakukan ekstraksi enam fitur tekstur, seperti contrast, correlation, energy, homogeneity, dissimilarity, dan Angular Second Moment (ASM). Seluruh fitur dari keempat sudut tersebut digabungkan menjadi satu vektor ciri tunggal untuk setiap citranya. Sebelum memasuki tahap pemodelan, vektor fitur gabungan tersebut dinormalisasi terlebih dahulu menggunakan metode MinMaxScaler guna menyelaraskan seluruh parameter ke dalam rentang skala 0 hingga 1 dan menghindari dominasi bias akibat perbedaan satuan nilai. Vektor fitur yang telah ditransformasikan inilah yang digunakan sebagai input untuk melatih model Support Vector Machine (SVM). Model SVM ini dikonfigurasikan melalui Kernel RBF (Radial Basis Function) dengan parameter C=50, serta mengaktifkan parameter probability=True guna mencari hyperplane pembatas yang optimal dalam memisahkan kelas COVID-19, Viral Pneumonia, dan Normal.

Lalu, untuk pendekatan metode modern, proses ekstraksi dan klasifikasi citra dilakukan secara otomatis di dalam jaringan syaraf tiruan. Citra input disiapkan dalam format warna asli (RGB 3-channel) berukuran 224x224x3 piksel yang nilai intensitasnya telah ditransformasikan ke skala -1 hingga 1 menggunakan fungsi bawaan preprocess_input MobileNet. Proses training ini menerapkan teknik Transfer Learning dengan memanfaatkan bobot awal atau pre-trained weights dari dataset ImageNet, di mana seluruh lapisan bawah

yang disebut base model dibekukan (trainable=False) untuk menjaga agar kemampuan ekstraksi fitur dasar ImageNet tidak rusak. Selanjutnya, dibangun arsitektur klasifikasi baru dengan menambahkan Global Average Pooling 2D untuk mereduksi dimensi fitur, lapisan Dense (128 neuron dengan menggunakan fungsi aktivasi ReLU), dan lapisan akhir Dense dengan fungsi aktivasi Softmax untuk menghasilkan probabilitas output tiga kelas. Model MobileNet ini dihimpun dengan menggunakan fungsi-fungsi optimasi. Proses training model dilakukan sebanyak 10 epochs dengan ukuran batch size yaitu 16, guna mengklasifikasikan kondisi COVID-19, Viral Pneumonia, dan Normal secara otomatis, stabil, dan efisien.

C. Untuk menjawab rumusan masalah mengenai perbandingan performa kedua metode, evaluasi dilakukan secara kuantitatif menggunakan metrik pengujian standar seperti *precision, recall, f1-score,* dan *accuracy*. Tabel di bawah ini menyajikan perbandingan performa hasil klasifikasi antara metode klasik *GLCM-SVM* dengan metode modern *MobileNet.*

Metode Klasifikasi	**Kelas Citra**	***Precision***	***Recall***	***F1-Score***	**Akurasi Global**
GLCM-SVM (Klasik)	COVID-19	0.96	0.96	0.96	86%
	Viral Pneumonia	0.75	0.90	0.82	
	Normal	0.88	0.70	0.78	
	Macro Average	0.86	0.85	0.85	
MobileNet (Modern)	COVID-19	1.00	1.00	1.00	97%
	Viral Pneumonia	0.91	1.00	0.95	
	Normal	1.00	0.90	0.95	
	Macro Average	0.97	0.97	0.97	



Gambar 3. *Heatmap Confusion Matrix* metode *GLCM-SVM* dan *MobileNet*

Berdasarkan hasil data *Confusion Matrix* untuk metode GLCM-SVM, persebaran deteksi dari 66 data uji adalah sebagai berikut:

- Kelas COVID-19: Berhasil mendeteksi 25 citra benar dan hanya 1 citra yang salah diklasifikasikan sebagai normal.
- Kelas Viral Pneumonia: Dari 20 citra rontgen, terdapat 18 citra yang berhasil diprediksi secara tepat. Terdapat 1 citra yang salah diklasifikasikan sebagai COVID-19 dan 1 citra lainnya salah diidentifikasi sebagai kondisi Normal.
- Kelas Normal: Dari 20 citra rontgen paru-paru sehat, terdapat tingkat kesalahan klasifikasi yang cukup tinggi di mana hanya 14 citra yang terdeteksi dengan benar dan 6 citra lainnya dianggap sebagai Viral Pneumonia.

Sebaliknya, pengujian menggunakan matriks kebingungan pada arsitektur jaringan saraf tiruan *MobileNet* menyajikan hasil klasifikasi yang sangat stabil dan mendekati sempurna:

- Kelas COVID-19: Seluruh 26 citra terprediksi secara akurat 100% benar dengan nilai *Precision*, *Recall*, dan *F1-score* mencapai angka tertinggi yaitu 1.00.
- Kelas Viral Pneumonia: Seluruh 20 citra terdeteksi dengan tepat secara sempurna *Recall* 1.00.
- Kelas Normal: Dari 20 data citra paru-paru normal, model memprediksi 18 citra secara benar, dan hanya ditemukan 2 citra tunggal yang meleset dikategorikan sebagai Viral Pneumonia.

Hasil penelitian secara jelas menunjukkan keunggulan mutlak pendekatan modern berbasis *deep learning (MobileNet)* dibandingkan dengan metode klasifikasi fitur tekstur statistik tradisional (*GLCM-SVM*). Akurasi global *MobileNet* yang mencapai 97% mengungguli *GLCM-SVM* yang hanya meraih nilai akurasi sebesar 86%. Terdapat selisih performa yang sangat signifikan, yakni sebesar 11%.

Ketidakmampuan *GLCM-SVM* dalam menyamai performa *MobileNet* berakar pada keterbatasan ekstraksi fitur spasial tekstur buatan manusia (*handcrafted features*). Matriks *GLCM* mengekstrak fitur statistik berdasarkan hubungan intensitas derajat keabuan piksel yang bertetangga (seperti *contrast*, *homogeneity*, *energy, dissimilarity dan ASM*). Meskipun metode *preprocessing CLAHE* telah mengoptimalkan kontras lokal, fitur statistik global tersebut kurang sensitif dalam membedakan sebaran spasial bercak putih paru-paru antara infeksi Viral Pneumonia yang cenderung masif di area tengah dengan kondisi paru-paru normal yang mengalami distorsi visual akibat faktor variasi pengambilan rontgen. Hal ini menyebabkan terjadinya misklasifikasi yang saling silang antara kelas Viral Pneumonia dan kelas Normal.

Di sisi lain, arsitektur *MobileNet* mengadopsi mekanisme pembelajaran representasi (*representation learning*). Melalui *layer-layer* konvolusi, model mampu mengekstrak fitur secara hierarkis mulai dari deteksi tepi, tekstur lokal halus, hingga pola semantik tingkat tinggi secara otomatis langsung saat proses pelatihan. Penggunaan teknik *depthwise separable convolution* pada *MobileNet* juga membuat model ini sangat efisien dalam pembaruan bobot tanpa kehilangan kapasitas diskriminatifnya. Kemampuan ini meminimalkan terjadinya *false negative* maupun *false positive* pada diagnosis penyakit kritis (COVID-19 dan Pneumonia), menjadikannya instrumen bantu radiologi digital yang jauh lebih aman, andal, dan presisi tinggi untuk diimplementasikan di dunia medis.

D. Analisis Lanjutan

Akurasi	**LBP**	***HOG***	***GLRLM***
	0,83	0,94	0,88

Analisis lanjutan pada penelitian ini dilakukan dengan mengkombinasi fitur ekstraksi tekstur terhadap metode klasifikasi SVM. Metode LBP menggabungkan GLCM dan Local Binary Pattern. Metode LBP memberikan nilai akurasi di angka 83% .

Selanjutnya metode HOG mengombinasikan fitur Gray Level Co-occurrence Matrix dan histogram of Oriented Gradients menghasilkan akurasi lebih tinggi dengan nilai 94%. Angka akurasi ini meningkat dibandingkan dengan metode GLCM-SVM klasik. Kombinasi ketiga metode tersebut mampu memberikan representasi tekstur dan bentuk objek secara lebih lengkap, sehingga model klasifikasi dapat mengenali karakteristik citra dengan lebih baik.

Penerapan metode GLRLM dilakukan dengan mengombinasikan GLCM dengan Gray Level Run Length Matrix. GLRLM menghasilkan akurasi 88%. Hal ini menunjukkan bahwa fitur run-length tekstur yang diekstraksi masih mampu mengenali pola citra, tetapi kurang optimal dalam menangkap detail penting dibanding HOG.

4. Kesimpulan dan Saran

Kesimpulan:

Berdasarkan seluruh tahapan penelitian yang telah dilakukan, dapat disimpulkan bahwa penerapan tahapan *preprocessing,* khususnya metode CLAHE, berhasil mengoptimalkan citra *Chest X-Ray* pasien yang redup dan berkabut dengan mempertegas detail visual flek putih patologis pada area paru-paru secara signifikan tanpa memicu kemunculan *noise* berlebihan. Pada tahap pengujian akhir, pendekatan modern berbasis *deep learning* (*MobileNet*) terbukti menunjukkan keunggulan mutlak dengan meraih akurasi global sebesar 97%, jauh mengungguli metode klasik *GLCM-SVM* yang hanya mencapai akurasi sebesar 86% dengan selisih performa signifikan sebesar 11%. Ketidakmampuan *GLCM-SVM* dalam menyamai performa ini berakar pada keterbatasan ekstraksi fitur statistik global buatan manusia (*handcrafted features*) yang kurang sensitif dalam membedakan sebaran spasial bercak putih paru-paru, sehingga memicu misklasifikasi saling silang. Sebaliknya, melalui mekanisme *representation learning* dan teknik *depthwise separable convolution, MobileNet* mampu mengekstrak fitur secara hierarkis dan otomatis selama 10 *epochs* pelatihan dengan sangat presisi, sehingga berhasil meminimalkan terjadinya *false negative* maupun *false positive* dan menjadikannya instrumen bantu radiologi digital yang jauh lebih aman, andal, serta akurat untuk mendeteksi COVID-19 dan Viral Pneumonia. Dan pada analisis lanjutan kami menemukan bahwa akurasi metode klasik (GLCM-SVM) jika ditambahkan fitur-fitur lain seperti HOG akurasinya meningkat sebesar 94%, diikuti GLRLM sebesar 88% dan LBP sebesar 83%. Hal ini menunjukan bahwa metode klasik (GLCM-SVM) mampu memberikan representasi citra yang baik. Namun demikian, akurasi dari seluruh pendekatan metode klasik tetap berada di bawah performa MobileNet.

Saran:

Untuk pengembangan, penyempurnaan, dan keberlanjutan penelitian di masa mendatang, terdapat beberapa saran yang direkomendasikan:

1. Penelitian selanjutnya dapat menggunakan jumlah dataset yang lebih besar dan lebih bervariasi agar model memiliki kemampuan lebih baik dalam mengenali berbagai kondisi paru-paru.
2. Pengembangan penelitian dengan membandingkan metode deep learning lainnya seperti ResNet, DenseNet, EfficientNet, atau Vision Transformer untuk mengetahui model yang paling optimal dalam klasifikasi citra medis.
3. Hasil Penelitian diharapkan dapat diimplementasikan lebih lanjut sebagai sistem pendukung diagnosis medis berbasis kecerdasan buatan guna membantu tenaga kesehatan dalam proses deteksi penyakit paru-paru secara lebih cepat dan akurat.

Daftar Pustaka

[1]. W. H. Organization, "Coronavirus disease (COVID-19) pandemic," 2020. https://www.who.int/europe/emergencies/situations/covid-19.

[2]. Bakheet, S., & Al-Hamadi, A. (2021). Automatic detection of COVID-19 using pruned GLCM-Based texture features and LDCRF classification. *Computers in biology and medicine*, *137*, 104781. https://doi.org/10.1016/j.compbiomed.2021.104781

[3]. M. A. Hossain, M. A. Hossain, M. M. Islam, and K. Andersson, “COVID-19 detection from chest X-ray images using CLAHE-YCrCb and machine learning algorithms,” *BMC Bioinformatics*, vol. 24, no. 1, pp. 1–19, 2023.

[4]. F. H. Najjar et al., “Classification of COVID-19 from X-ray images using GLCM features and machine learning,” *Malaysian Journal of Fundamental and Applied Sciences*, vol. 19, no. 3, 2023.

[5]. M. Siddhartha and A. Santra, “COVIDLite: A depth-wise separable deep neural network with white balance and CLAHE for detection of COVID-19,” arXiv preprint arXiv:2006.13873, 2020.

[6]. S, K. S., Taufik, I., Dharma, D. F., & Hidayat, M. (2021). Analisis Perbaikan Kualitas Citra Menggunakan CLAHE dan HE Pada Citra X-Ray Covid-19 dan Pneumonia. *IJCIT (Indonesian Journal on Computer and Information Technology)* , 97-104.

[7]. Ghani, A. D., Intan, I., & Eizal, M. (2023). MobileNet Classifier for Detecting Chest X-Ray Images of COVID-19 Based On Convolutional Neural Network. *ILKOM Jurnal Ilmiah*, 488-497.

[8]. Godbin, A. B., & Jasmine, S. G. (2023). Screening of COVID-19 Based on GLCM Features from CT Images Using Machine Learning Classifiers. *SN computer science*, *4*(2), 133. https://doi.org/10.1007/s42979-022-01583-2

[9]. Ramadhani, E. P., & Rochmawati, N. (2022). Klasifikasi Covid-19 Pada Citra CT-Scan Dengan Mengombinasikan Metode Convolutional Neural Network Dan Support Vector Machine. *JINACS (Journal of Informatics and Computer Science)*.

[10]. Salve, H. S. (2026). *Transfer learning for medical imaging: An empirical evaluation of CNN architectures on chest radiographs* [Preprint]. medRxiv. https://doi.org/10.64898/2026.01.07.26343591